

01 Agent 能力

推理规划与指令遵循 133 条目 · 1,568 题 ●★τ³-bench 192 ●★ToolLLM 102 ●MCP-Atlas 94 ●★HLE 89 ●BixBench 85 其余 39 个系列 1006	任务完成与产物交付 116 条目 · 1,378 题 ●★τ³-bench 200 ●★ToolLLM 122 ●★HLE 89 ●BixBench 85 ●MemoryAgentBench 75 其余 34 个系列 807	代码与外部工具执行 72 条目 · 760 题 ●★ToolLLM 105 ●BixBench 85 ●★SWE-bench Verified 57 ●★BFCL V4 Multi-Turn 53 ●★Terminal-Bench 53 其余 20 个系列 407	数据处理与分析 64 条目 · 753 题 ●★ToolLLM 111 ●MCP-Atlas 94 ●BixBench 85 ●★SWE-bench Verified 57 ●DSBench 50 其余 17 个系列 356
信息检索与网页操作 30 条目 · 344 题 ●★ToolLLM 118 ●MCP-Atlas 84 ●★τ³-bench 52 ●AgentBoard 27 ●★GAIA 22 其余 3 个系列 41	文档与办公工具 15 条目 · 161 题 ●EntCollabBench 52 ●★SpreadsheetBench 27 ●★GAIA 22 ●★DocVQA 15 ●Microsoft PPT-Eval 15 其余 2 个系列 30	多模态理解 14 条目 · 169 题 ●★HLE 65 ●★GAIA 33 ●★DocVQA 15 ●Microsoft PPT-Eval 15 ●OfficeBench 15 其余 2 个系列 26	记忆管理 6 条目 · 109 题 ●MemoryAgentBench 75 ●PersonaMem 22 ●Memory Temporal Reasoning 12
协作与任务分工 10 条目 · 135 题 ●★BFCL V4 Multi-Turn 53 ●EntCollabBench 52 ●AWS Multi-agent 30	执行闭环与状态维护 38 条目 · 440 题 ●★τ³-bench 162 ●★SWE-bench Verified 57 ●★BFCL V4 Multi-Turn 53 ●AlgoTune 41 ●AutomationBench 29 其余 7 个系列 98	成本效率与运行可靠性 97 条目 · 1,161 题 ●★τ³-bench 200 ●★ToolLLM 122 ●MCP-Atlas 94 ●★HLE 89 ●★SWE-bench Verified 57 其余 27 个系列 599	安全与权限边界 12 条目 · 150 题 ●★τ³-bench 76 ●★ToolLLM 35 ●EntCollabBench 27 ●AgentOps-Bench 12

02 行业场景

金融、银行与保险 14 条目 · 157 题 ●★τ³-bench 50 ●★ToolLLM 44 ●SkillsBench 22 ●AWS Multi-agent 15 ●Frontier-Eng 15 其余 3 个系列 11	零售电商与客户服务 12 条目 · 130 题 ●★τ³-bench 50 ●MCP-Atlas 30 ●MemoryAgentBench 25 ●★Spider 2.0 11 ●★ToolLLM 9 ●AutomationBench 5	销售、广告与营销 14 条目 · 155 题 ●MCP-Atlas 81 ●CRMarena-Pro 40 ●★ToolLLM 24 ●AutomationBench 10	法务、隐私与合规 8 条目 · 57 题 ●EntCollabBench 52 ●★Terminal-Bench 5
企业办公与人力资源 15 条目 · 177 题 ●AgentBoard 40 ●★SpreadsheetBench 27 ●MemoryAgentBench 25 ●★DocVQA 15 ●Microsoft PPT-Eval 15 其余 5 个系列 55	软件、IT 与网络安全 25 条目 · 290 题 ●★SWE-bench Verified 57 ●MemoryAgentBench 50 ●FeatureBench 40 ●★Terminal-Bench 26 ●GSO 23 其余 8 个系列 94	通信与公共事业 5 条目 · 59 题 ●★τ³-bench 50 ●★Terminal-Bench 5 ●★ToolLLM 4	制造、物流与供应链 13 条目 · 142 题 ●MCP-Atlas 34 ●DSBench 30 ●Frontier-Eng 30 ●AlgoTune 13 ●★Spider 2.0 12 其余 4 个系列 23
医疗、生命科学与化学 13 条目 · 142 题 ●BixBench 85 ●AlgoTune 13 ●★HLE 13 ●★GPQA Diamond 11 ●DSBench 10 其余 2 个系列 10	科研、数学与教育 39 条目 · 460 题 ●★HLE 89 ●BixBench 85 ●AlgoTune 41 ●★ARC-AGI-2 35 ●Build Word2Vec 20 其余 15 个系列 190	文娱、媒体与生活服务 12 条目 · 132 题 ●★ToolLLM 39 ●★HLE 35 ●★GAIA 22 ●PersonaMem 11 ●★Spider 2.0 11 其余 2 个系列 14	交通、旅游与房地产 13 条目 · 142 题 ●★τ³-bench 50 ●AWS Multi-agent 15 ●MCP-Atlas 13 ●★Spider 2.0 12 ●★GAIA 11 其余 4 个系列 41